

Защита выпускной квалификационной работы

Факультет систем управления и робототехники

Университет ИТМО

ИТМО

**Исследование применения обучения с
подкреплением для повышения эффек-
тивности управления роботами с исполь-
зованием визуально-языковых моделей**

Направление подготовки: 15.03.06 Мехатроника и робототехника

Студент: Новичков Дмитрий Евгеньевич, гр. 3435

Научный руководитель: Ведяков А.А., к.т.н., доцент ФСУиР

Санкт-Петербург, 2026

VLA-модели (Vision-Language-Action) управляют роботом по инструкции на естественном языке, объединяя зрение, понимание языка и моторное управление.

- В реальных условиях доля успехов **70–80 %** – недостаточно для практики
- RL – путь довести её до **98–99 %**, но единой методики интеграции нет

Взрывной рост области

Конференция	Работ по VLA
ICLR 2024	1
ICLR 2025	9
ICLR 2026	164

×18 за год

Цель

Повышение эффективности управления роботом-манипулятором при выполнении задач, заданных на естественном языке, за счёт интеграции методов обучения с подкреплением (RL) с визуально-языковыми моделями действий (VLA).

Задачи:

1. Аналитический обзор VLA-моделей и способов их интеграции с RL (2023–2026 гг.)
2. Классификация методов интеграции RL и VLM по трём направлениям
3. Разработка методики вычислительного эксперимента и метрик оценки
4. Реализация программного прототипа (residual RL + VLM-генерация наград)
5. Проведение серий экспериментов на LIBERO и MetaWorld
6. Анализ результатов и формулировка методических рекомендаций

Три направления интеграции RL и VLM/VLA

Направление	Идея	Результат	Работы
RL-дообучение VLA	RL уточняет готовую VLA-политику	98–99 % успехов	PLD, STARE-VLA
VLM → награда	VLM генерирует функцию вознаграждения	лучше эксперта на 83 % задач	EUREKA, Text2Reward
VLM-планировщик	VLM ставит подзадачи, RL исполняет	87,5 % на реальном роботе	SayCan, Embodied-R1

Фокус работы

Основное: RL-дообучение девяти VLA-моделей на LIBERO. **Дополнительно:** VLM-генерация наград на MetaWorld (сценарий без готовой VLA).

Класс	Модели
Авторегрессионные	OpenVLA-OFT, UniVLA, RT-1-X
Flow-matching диффузия	/ π_0 , π_0 -fast, CogACT
Пространственно- обусловл.	SpatialVLA
Компактные генера- листы	SmolVLA, Octo-Small

Тенденции:


- Масштаб: **35M** – **8B** параметров
- Открытые модели догоняют закрытые
- Закрытые ($\pi_{0,5}$, Gemini Robotics) лидируют

Проблема

Даже лучшие VLA упираются в потолок без RL – особенно на длинноразрешенных задачах.

Метод: residual RL с замороженной VLA

- Базовая VLA заморожена, обучается лёгкий SAC-агент коррекции действия
- Итоговое действие:
$$a_t = \pi_{\text{VLA}}(o_t, l) + \Delta \pi_{\text{RL}}(s_t)$$
- Residual-сеть: 256/256 ReLU; вход – визуальный эмбединг + проприоцепция + текст
- Стадийная награда:** Reach → Grasp → Transport → Place




Инфраструктура

NVIDIA A100, SAC (Stable-Baselines3), буфер 10^6 , 300 тыс. шагов/набор, 3 seed, ≈ 200 GPU-часов.

Четыре фазы манипуляции

$$R_{\text{stage}}(s_t) = \sum_{k=1}^4 w_k \cdot \mathbf{1}[\text{phase}_k \text{ выполнена}] + \beta \cdot S(T_i)$$

$w_k = \{0,25; 0,25; 0,25; 0,25\}$, $\beta = 1,0$ – бонус за успех эпизода.



Детекция фаз – по проприоцепции ROBOSUITE (положение захвата, контакт, расстояние до цели).

Постановка эксперимента

#	Серия	Модели
1	VLA-baseline без RL	9 VLA
2	Сравнение RL-схем	OpenVLA-OFT
3	RL всех VLA (осн.)	9 VLA
4	Абляция компонент	OpenVLA-OFT
5	VLM-награда (доп.)	Qwen2.5-VL+SAC

Бенчмарк LIBERO


- 4 набора $\times$ 10 задач: Object, Spatial, Goal, Long
- Franka Panda, ROBOSUITE
- 10 эпизодов/задачу, 3 seed
- Метрики: SR, 95 % ДИ, sample efficiency, $\rho(R, S)$

Серия 1: baseline девяти VLA на LIBERO

Модель	Obj.	Spat.	Goal	Long	Парам.	Средн.
OpenVLA-OFT-7B	98,4	97,6	97,9	94,5	7B	97,1
UniVLA-7B	97,0	96,5	95,5	91,0	7B	95,0
π_0 -3B	97,5	95,0	94,5	89,0	3B	94,0
CogACT-8B	95,5	94,5	93,0	89,0	8B	93,0
SmolVLA-2.2B	95,5	94,0	92,0	88,5	2,2B	92,5
π_0 -fast-3B	94,0	92,5	90,0	86,0	3B	90,6
SpatialVLA-4B	91,0	90,0	88,0	83,0	4B	88,0
Octo-Small	90,5	88,0	85,5	80,0	120M	86,0
RT-1-X	88,0	86,0	82,0	75,5	35M	82,9


OpenVLA-OFT лидирует ($97,1\% \pm 0,4\%$). Наибольший разброс – на наборе **Long** (94,5 vs 75,5 %): длинноразрешенные задачи требуют устойчивого захвата и переноса.

Серия 3: residual RL повышает SR всех 9 VLA



Прирост +1,5 ... +4,1 п.п.; лучший – OpenVLA-OFT 97,1 → 98,6 %. Наибольший прирост у самой слабой модели (RT-1-X, +4,1 п.п.).

Серия 3: прирост RL и baseline



Интерпретация

RL корректирует систематические ошибки, которых больше у слабых политик.

- Сильные модели (UniVLA, π_0):
+1,8 ... +2,4 п.п.
- Слабые (Octo, RT-1-X):
+3,9 ... +4,1 п.п.
- Отчасти – эффект потолка бенчмарка, а не только RL

Серии 2 и 4: выбор RL-схемы и абляция

Серия 2: схемы RL (OpenVLA-OFT)

Метод RL	Средн.	Δ
Baseline (без RL)	97,1	–
Residual SAC + stage	98,6	+1,5
STARE-PPO + stage	98,2	+1,1
Direct SAC (unfrozen)	96,5	–0,6


Серия 4: абляция (Spatial)

Конфигурация	Δ
Полная (residual SAC + stage)	+1,5
Без стадийной награды (sparse)	+0,7
Unfrozen VLA (direct SAC)	–0,6
PPO вместо SAC	+0,9
Бюджет 150k (вместо 300k)	+0,8

Выводы

Заморозка VLA **предпочтительна** (разморозка $\rightarrow$ катастрофическое забывание).
 Стадийная награда: **+0,8 п.п.** над разреженной; SAC $>$ PPO на **+0,6 п.п.**


Анализ отказов по фазам манипуляции



OpenVLA-OFT на LIBERO-Long.


- Суммарные неудачи: **5,5 %** → **3,0 %**
- Основной выигрыш – финальная фаза **Place** (−1,9 п.п.)
- Ранние фазы (Reach, Grasp) и так редки – RL почти их не трогает

Residual-агент компенсирует систематическое смещение при размещении, не переобучая VLA.



- Основной прирост – до 150k шагов, далее плато ($\pm 0,2$ п.п.)
- Стадийная награда сокращает выход на 95 % SR с 220k до **165k** (–25 %)
- Direct SAC после подъёма **деградирует** – катастрофическое забывание

Примеры эпизодов: до и после RL



OpenVLA-OFT на LIBERO. После RL residual-агент устраняет промах на фазе Place – объект устойчиво размещается в целевой позиции.

SR (%), SAC, 500k шагов

Награда	reach	push	pick-pl.
Экспертная	100	90,0	65,0
Разреженная	100	10,0	0,0
VLM, 1 итер.	100	48,3	13,3
VLM, 3 итер.	100	85,0	46,7

Рефлексия на push-v3

Итер.	SR	$\rho(R, S)$
1	48,3	0,12
2	72,0	0,58
3	85,0	0,81

Наблюдения

Без готовой VLA: язык. модель генерирует код награды. За 3 итерации push 48 $\rightarrow$ 85 %, ρ растёт синхронно с SR. SAC устойчивее PPO (reach: 100 vs 71,7 %).

Сравнение с результатами из литературы

Метод / работа	SR, %	Бюджет RL	Примечание
OpenVLA-OFT (baseline)	97,1	–	Без RL
SimpleVLA-RL	99,0	$\geq 1\text{M}$ шагов	GRPO, full-model
PLD	99,0	$\geq 1\text{M}$ шагов	Residual RL + дистилляция
RIPT-VLA	97,5	critic-free	LOOP, sparse
VLA-RL	97,0	$\geq 1\text{M}$ шагов	process RM
Настоящая работа	98,6	300k/набор	9 VLA, residual SAC + stage

98,6 % – выше RIPT-VLA и VLA-RL, лишь на 0,4 п.п. ниже SimpleVLA-RL/PLD при бюджете в **3+** раза меньше и без полнополитического дообучения VLA.

1. Residual RL со стадийным вознаграждением стабильно повышает SR всех девяти VLA на LIBERO (+1,5 ... +4,1 п.п.); лучший результат – 98,6 %.
2. Прирост обратно пропорционален baseline ($\rho = -0,97$): RL «вытягивает» слабые модели.
3. Заморозка базовой VLA **предпочтительна**: end-to-end разморозка деградирует (−0,6 п.п.).
4. Стадийная награда (+0,8 п.п.) и SAC (>PPO на 0,6 п.п.) – ключевые компоненты; основной выигрыш – на фазе Place.
5. Доп. серия: VLM-награды требуют 3+ итераций на контактных задачах; $\rho(R, S) > 0,8$ – надёжный предиктор успеха.
6. **Рекомендации**: есть VLA (SR>90 %) → residual RL со стадийной наградой; нет VLA → VLM-генерация награды с итеративным уточнением.
7. Открытый код: github.com/mfclabber/bachelor-thesis

- **Увеличение бюджета** RL-дообучения (500k–1M шагов) – ожидается приближение к 99 % SR.
- **Дистилляция** residual-политики обратно в VLA – отказ от надстройки на инференсе.
- **Перенос на реальный робот**: оценка sim-to-real разрыва (SIMPLER).
- **Единый конвейер** VLM-награда → дистилляция → residual RL.

Спасибо за внимание!

it's **MO**re than a
UNIVERSITY